

Desentrañando la trampa de la informalidad: Un enfoque de Machine Learning para el diagnóstico de la vulnerabilidad estructural en Ecuador

Unraveling the Informality Trap: A Machine Learning Approach to Diagnosing Structural Vulnerability in Ecuador

Autores y afiliación

Alex Jhair Uyaguari Ochoa^{1*}

¹ Universidad Nacional de Loja – Maestría en Big Data y Ciencia de Datos, Loja, Ecuador.

Correo: alex.uyaguari@unl.edu.ec, ORCID: <https://orcid.org/0009-0000-0134-6888>

Contribución de autor:

Alex Jhair Uyaguari Ochoa: Conceptualización; Curación de datos; Análisis formal; Investigación; Metodología; Software; Validación; Visualización; Redacción – borrador original.

Financiamiento: La presente investigación no recibió financiamiento externo.

Autor para correspondencia (*): alex.uyaguari@unl.edu.ec

Resumen: La informalidad constituye un desafío estructural en las economías en desarrollo. Este estudio predice el empleo en el sector informal en Ecuador mediante microdatos nacionales de 2024 y algoritmos de Machine Learning ponderados por factores de expansión poblacional para garantizar representatividad nacional. Con un XGBoost central se obtiene un AUC-ROC de 90%, donde la dinámica laboral y el capital humano concentran el 83,83% de la importancia relativa, evidenciando una heterogeneidad de riesgo entre actividades económicas. Para predecir la informalidad en la población desocupada, se desarrolla un modelo de vulnerabilidad latente que, al excluir variables de flujo laboral, se centra en determinantes pre-mercado, logrando un AUC-ROC del 82%. En esta especificación, el capital humano domina la predicción (67,50%) frente a las dimensiones de hábitat e infraestructura (32,50%). Específicamente, la escolaridad actúa como el principal factor protector, frente a la precariedad habitacional y de servicios que elevan el riesgo de informalidad. La inferencia prospectiva identifica un riesgo promedio del 38,70% y una tasa latente del 33,30%, indicando que un tercio de los desempleados enfrenta un alto riesgo de inserción informal. Los hallazgos sugieren una trampa estructural que exige políticas de inversión, formalización empresarial, educación técnica y cierre de brechas en infraestructura básica.

Abstract: Informality represents a structural challenge in developing economies. This study predicts employment in the informal sector in Ecuador using 2024 national microdata and Machine Learning algorithms weighted by population expansion factors to ensure national representativeness. A central XGBoost model achieves an AUC-ROC of 90,0%, with labor dynamics and human capital accounting for 83,83% of the relative importance, revealing risk heterogeneity across economic activities. To predict informality among the unemployed population, a latent vulnerability model was developed; by excluding labor flow variables, it focuses on pre-market determinants, achieving an AUC-ROC of 82,0%. In this specification, human capital dominates the prediction (67,50%) compared to habitat and infrastructure dimensions (32,50%). Specifically, schooling acts as the primary protective factor, whereas precarious housing and services increase informality risk. Prospective inference identifies an average risk of 38,70% and a latent rate of 33,30%, indicating that one-third of the unemployed face a high risk of informal insertion. The findings suggest a structural trap requiring policies for investment, business formalization, technical education, and the closure of basic infrastructure gaps.

Palabras clave: Informalidad laboral, machine learning, inferencia prospectiva, factores socioeconómicos, desocupados.

Keywords: Labor informality, machine learning, prospective inference, socioeconomic factors, unemployed.

Código JEL: J46; C45; C53; O15; J64

1. Introducción

La informalidad laboral es uno de los rasgos estructurales más persistentes de las economías emergentes. Conforme a la Organización Internacional del Trabajo (OIT, 2025), aproximadamente el 51% de los trabajadores de América Latina y el Caribe se encontraban en empleo informal, reflejando limitaciones en el acceso a protección social y estabilidad laboral.

En Ecuador, el escenario supera el promedio regional; cifras de la OIT sitúan la tasa de informalidad en un 67,31%. Así como, datos del Instituto Nacional de Estadística y Censos (INEC, 2025) confirman esta tendencia al alza: la ocupación en el sector informal aumentó de un 47,8% en 2019 a un 51,5% en 2025.

Esta persistencia no es un fenómeno coyuntural, sino una manifestación de segmentación laboral estructural (Canelas, 2019) que representa alrededor del 32% de la estructura productiva del país (Mejía Chávez et al., 2023). A nivel macroeconómico, la informalidad se asocia a la carga tributaria, la calidad institucional, el empleo agrícola y el autoempleo (Asllani et al., 2025). Según el directorio de empresas del INEC (2025), las microempresas constituyen el 92% de las firmas registradas. Este sector prioriza el empleo informal y se caracterizan por la inestabilidad (Bulale e Ibrahim, 2026). Las consecuencias radican en la erosión de la base impositiva y la exacerbación de la vulnerabilidad de los hogares ante choques macroeconómicos, donde la informalidad actúa simultáneamente como red de seguridad y amplificador de crisis (Nguyen y Ho, 2025; Torres-Favela y Luna, 2025).

La literatura coincide en que la inserción informal se asocia a características socioeconómicas individuales. En Ecuador, los inmigrantes enfrentan barreras sistemáticas de acceso a empleos formales (Díaz-Sánchez y Correa, 2024), mientras que el desempleo persistente motiva la participación en el comercio informal (Martínez Valarezo et al., 2022). Asimismo, el acceso a un empleo adecuado para la población joven se ve condicionado por la interseccionalidad entre género, estado civil y capital humano (Da Silva Bichara et al., 2022).

Pese al predominio de modelos Logit/Probit, persiste una brecha en la captura de patrones laborales complejos. Esta investigación emplea Machine Learning para responder: ¿cuál es el rol de los factores socioeconómicos en la configuración de la informalidad y en la estimación del riesgo de vulnerabilidad latente para los desocupados? El estudio aporta cuatro contribuciones: 1) integra dimensiones sociolaborales y de hábitat; 2) aplica aprendizaje automático; 3) identifica predictores relevantes; y 4) desarrolla un modelo de inferencia prospectiva para proyectar el riesgo de inserción informal. Al diagnosticar la precariedad antes de la vinculación laboral efectiva, se aporta en desentrañar la vulnerabilidad estructural.

2. Revisión de literatura

2.1. Fundamentación teórica

La base teórica converge en tres paradigmas: el dualismo de Lewis (1954), que plantea un mercado segmentado donde el sector informal absorbe el excedente de mano de obra; el estructuralismo por Tokman (1979), que describe una subordinación heterogénea en el mercado laboral; y la teoría del capital humano Becker (1992), que vincula la informalidad con bajos niveles de inversión en educación y experiencia. Estos marcos son operativizados por el INEC y la OIT al definir el sector informal por la unidad económica y la ausencia de Registro Único de Contribuyentes (RUC), subrayando que la informalidad reside en la precariedad institucional de la empresa más que en el vínculo contractual (Molina Vera et al., 2015). Esto permite diferenciar técnicamente entre el "empleo informal" (vínculo laboral) y "empleo en el sector informal" (unidad productiva) que es el conjunto de personas que operan en estas unidades no registradas, siendo este último el núcleo de análisis de la presente investigación.

2.2. Evidencia empírica: determinantes macro y microeconómicos

La informalidad es un fenómeno sistémico que en Ecuador representa el 32% del PIB (Mejía Chávez et al., 2023), cifra consistente con el promedio del 33,5% en economías emergentes (Asllani et al., 2025). Su persistencia se asocia a variables cíclicas, donde el gasto público y la oferta monetaria (Mejía Chávez et al., 2023), así como las crisis financieras (Nguyen y Ho, 2025), actúan como catalizadores de empleo informal. Aunque este funciona como refugio, su expansión involuntaria degrada la estabilidad macroeconómica a largo plazo (Torres-Favela y Luna, 2025). Mientras que, a nivel micro, la inserción laboral está condicionada por la bidireccionalidad entre pobreza e informalidad (Canelas, 2019), enfrentando los informales una "penalización salarial" persistente incluso tras controlar por capital humano (Bargain et al., 2021). La segmentación se agudiza por el género, la maternidad, rigideces domésticas (Berniell et al., 2021; Jara y Rattenhuber, 2022) y el nivel educativo (Castillo et al., 2022). Asimismo, la migración impone barreras sistémicas (Díaz-Sánchez y Correa, 2024), donde las necesidades de supervivencia prevalecen sobre las regulaciones (Martínez Valarezo et al., 2022).

2.3. Vulnerabilidad estructural, hábitat y movilidad

Emergentemente, la literatura vincula las condiciones de vida extralaborales con la informalidad. Choques climáticos y deficiencias habitacionales impulsan una informalidad de subsistencia (Llerena Pinto et al., 2025), agravada por la exclusión financiera y trampas de liquidez (Aurazo y Gasmi, 2025). Este ciclo restringe la movilidad intergeneracional; en Ecuador, solo el 10,6% de hijos en el quintil inferior logra ascenso socioeconómico (Del Pozo y Moreno, 2024), debido a que el sector informal estanca el aprendizaje de habilidades, perpetuando la baja productividad (Bobba et al., 2021).

2.4. Del modelado econométrico al paradigma del Machine Learning

El modelado ha transitado de enfoques lineales (Logit/Probit) hacia el ML para gestionar la alta dimensionalidad y capturar interacciones complejas (Castillo et al., 2022; Da Silva Bichara et al., 2022). Algoritmos como Gradient Boosted Trees y XGBoost han demostrado una precisión superior (78%-88%) en la identificación de la informalidad (Castillo et al., 2023; Maia de Souza et al., 2025; Franco Coello et al., 2025). Además de la clasificación, el ML permite reevaluar la importancia de las variables. Redes neuronales y técnicas de Stacking superan a los métodos latentes tradicionales (MIMIC) al capturar patrones temporales y estructurales (Felix et al., 2024; Narváez y Herrera, 2025). Ante la fragmentación de estudios previos, surge la necesidad de integrar nuevas variables socioeconomías mediante enfoques de ciencia de datos.

3. Materiales y métodos

3.1. Datos

Los datos provienen de la Encuesta Nacional de Empleo, Desempleo y Subempleo (ENEMDU), que proporciona información actualizada sobre el mercado laboral ecuatoriano. Se integraron los módulos de personas y vivienda mediante un procedimiento de coincidencia de identificadores, consolidando 150 000 observaciones a nivel individual. La muestra se restringió a la población de 15 a 65 años, rango que constituye el núcleo de la fuerza laboral del

país. El procesamiento se ejecutó en el entorno R, empleando el ecosistema tidyverse para la ingeniería de datos y el marco de trabajo tidymodels para la especificación de los modelos.

3.2. Variables

La variable dependiente se mide a partir de la sectorización del empleo del trabajador, clasificada por el INEC bajo lineamientos de la OIT según las características de la unidad económica. El sector informal se identifica por la ausencia de Registro Único de Contribuyentes y la pequeña escala de la unidad productiva. La variable fue recodificada como dicotómica (informal = 1; no informal = 0), omitiendo el empleo doméstico y categorías no clasificadas para asegurar la comparabilidad. La selección de variables explicativas siguió un protocolo diseñado para maximizar el poder predictivo y mitigar sesgos, donde se contempla tres fases:

Mitigación proactiva de la fuga de datos (data leakage): Para evitar tautologías metodológicas e identificar mecanismos subyacentes sobre relaciones triviales, se excluyeron las variables que integran la definición institucional de informalidad (RUC, registros contables y tamaño del establecimiento), así como proxies excesivas (sitio de trabajo y categoría de ocupación).

Evaluación de la fuerza de asociación no paramétrica: La selección de variables categóricas empleó la prueba Chi-cuadrado χ^2 y el coeficiente V de Cramer (umbral $> 0,10$). Para las variables numéricas, se utilizó el área bajo la curva ROC (AUC) univariada, priorizando aquellas con valores superiores a 0,5 para garantizar una capacidad discriminatoria mínima.

Análisis de redundancia y colinealidad: Mediante correlaciones cruzadas (Pearson y V de Cramer), se eliminaron dimensiones redundantes con correlaciones superiores a 85%, priorizando la "rama de actividad" para capturar la heterogeneidad sectorial. Se consolidaron seis dimensiones analíticas: 1) capital humano, 2) sociodemográfico, 3) laboral, 4) habitacional, 5) infraestructura y 6) estabilidad patrimonial. Este diseño se complementa con la capacidad intrínseca de los algoritmos de árboles para excluir predictores con posible aporte nulo.

3.3. Procesamiento datos e ingeniería de variables

Las variables continuas fueron sometidas a winsorización para tratar valores atípicos. La escolaridad se transformó en una escala acumulativa de años aprobados. Los ingresos laborales, preservados con fines comparativos, recibieron imputación por K vecinos cercanos (KNN) y transformación logarítmica; adicionalmente, los ingresos negativos se codificaron como cero y se capturaron mediante la variable binaria "gasta más" como indicador de estrés financiero. La experiencia laboral se imputó siguiendo la convención de Mincer (1974): edad menos años de escolaridad menos seis, asegurando consistencia de los datos. La Tabla 1 muestra las variables empeladas. Las variables categóricas se reagrupan para mitigar desbalances (ver Anexo A).

Tabla 1. Descripción de variables de los modelos

Dimensión	Variable	Símbolo	Medida	Definición
Dependiente	Empleo sector informal	informal	Dicotoma	Indicador binario de la condición de ocupación en el sector informal
Dotación de Capital Humano	Escolaridad	esc	Años	Número acumulado de años de escolaridad aprobados

	Experiencia laboral	exp_lab	Años	Experiencia laboral acumulada en años de trayectoria
	Edad	edad	Años	Años de la persona
Características sociodemográficas	Etnia	etnia	Politómica	Identidad étnico-racial auto percibida, consolidada en grupos.
	Estado civil	estado_civil	Politómica	Situación conyugal o legal del individuo
	Género	género	Politómica	Clasificación de género hombre o mujer
	Área	area	Dicótoma	Clasificación geográfica de residencia
Estructura y dinámica laboral	Rama de actividad	rama1	Politómica	Sector de actividad económica de la unidad productiva donde el individuo desempeña su ocupación principal
	Ingresos laborales	ingrl_log	Logaritmo	Transformación logarítmica de ingresos
	Horas de trabajo	hrs_trab	Horas	Horas de trabajo principal a la semana
	Deseo de trabajar	deseo_trab	Politómica	Indicador de presión laboral o subempleo por insuficiencia de horas de trabajo
Estructura habitacional	Material del piso	mat_piso	Politómica	Calidad de durabilidad del material predominante en el suelo de la vivienda
	Material del techo	mat_techo	Politómica	Indicador estructural según el material de la cubierta superior de la vivienda
	Material de paredes	mat_pared	Politómica	Nivel estructural de los materiales de los muros exteriores de la vivienda
Infraestructura de servicios	Saneamiento	serv_sanit	Politómica	Calidad de la infraestructura sanitaria y del sistema de eliminación de excretas
	Servicio de higiene	serv_ducha	Politómica	Disponibilidad y privacidad del servicio de higiene
	Suministro de agua	agua_fuente	Politómica	Origen y seguridad del suministro de agua para uso doméstico
	Acceso a la vivienda	via_acceso	Politómica	Nivel de conectividad y accesibilidad del hogar al entorno urbano o vial
	Eliminación basura	basura_disp	Politómica	Método eliminación de residuos
	Material de cocción	mat_cocina	Politómica	Fuente de energía para la cocción
Estabilidad patrimonial del hogar	Tipo de vivienda	tipo_viv	Politómica	Caracterización de la tipología habitacional según su nivel de consolidación

Tenencia de vivienda	tenencia_viv	Politómica	Relación jurídica o contractual del hogar con la posesión del inmueble
Número de cuartos	num_cuartos	unidad	Capacidad habitacional en cuartos
Déficit financiero	gasta_mas	Dummy	Escenario financiero donde el consumo excede los ingresos

Elaboración propia

3.4. Modelamiento

El flujo de modelamiento desarrollado mediante el ecosistema tidymodels, consideró una partición estratificada del 80% para entrenamiento y 20% para prueba. La arquitectura incluyó una receta de preprocesamiento con codificación “one hot”, tratamiento de niveles poco frecuentes y filtrado de variables con varianza cercana a cero. Para garantizar la representatividad poblacional, los factores de expansión del INEC fueron operacionalizados como pesos de importancia integrados en el flujo de entrenamiento y en una validación cruzada estratificada de 5 pliegues. Mientras que, el proceso de optimización de hiperparámetros se ejecutó mediante una búsqueda en grilla “Latin Hypercube”, maximizando el área bajo la curva.

3.4.1. Regresión logística regularizada (Elastic Net)

La regresión logística sirve como línea base de predicción y obtención de coeficientes. La probabilidad de que un individuo i pertenezca al sector informal ($Y_i = 1$) se define mediante:

$$(Y_i = 1|X_i) = \frac{1}{1 + e^{-(\beta_0 + X_i\beta)}} \quad (1)$$

Donde X_i son las variables explicativas. Siendo X_i igual a: capital humano (H_i), factores sociodemográficos (S_i), estructura laboral (L_i), habitabilidad (V_i), infraestructura (I_i) y patrimonio (A_i). Hibe (2025), detalla que los parámetros se estiman mediante regularización:

$$\min_{\beta} \left\{ -\frac{1}{n} \sum_{i=1}^n [y_i \ln(P_i) + (1 - y_i) \ln(1 - P_i)] + \lambda \left[\frac{1 - \alpha}{2} \|\beta\|_2^2 + \alpha \|\beta\|_1 \right] \right\} \quad (2)$$

Donde λ es la penalización y α regula la mezcla de penalización Ridge (L_2) y Lasso (L_1). Para su análisis se consideró tanto sus coeficientes como las importancias relativas por variable.

3.4.2. Bosques aleatorios (Random Forest)

Este modelo busca capturar interacciones no lineales y reducir la varianza de los estimadores (Iranzad y Liu, 2025). El modelo estima la función $\hat{f}(\cdot)$ como el promedio de $b = 500$ árboles $T_b(\cdot)$ construidos sobre muestras aleatorias y mediante selección aleatoria de atributos:

$$\hat{f}(H_i, S_i, L_i, V_i, I_i, A_i) = \frac{1}{B} \sum_{b=1}^{500} T_b(H_i, S_i, L_i, V_i, I_i, A_i) \quad (3)$$

La arquitectura se optimiza por validación cruzada para ajustar la profundidad de los nodos (mtry) y el tamaño mínimo de las hojas (min_n), mejorando la generalización.

3.4.3. Potenciación de Gradiente (XGBoost) y Extensión Prospectiva

Por último, se desarrolló el algoritmo de potenciación de gradiente extremo (XGBoost), que emplea un aprendizaje aditivo secuencial para minimizar los errores residuales de las iteraciones previas (Ali et al., 2023). Se constituye como:

$$\hat{y}_i = \sigma \left(\sum_{k=1}^{500} \eta \cdot f_k(x_i) \right) \quad (4)$$

Donde, $\hat{y}_i$ es la probabilidad de ocurrencia. $\sigma(\cdot)$ que es la función logística, f_k representa el k -ésimo árbol y η es el parámetro de escala que pondera la contribución de cada nuevo modelo al ensamble global para mitigar el riesgo de sobreajuste. La $f_k(x_i)$ es la predicción individual de un árbol. El proceso se rige por:

$$\text{Obj}(\phi) = \sum_i L(y_i, \hat{y}_i) + \sum_{k=1}^{500} \left[\gamma T + \frac{1}{2} \lambda |w|^2 \right] \quad (5)$$

Las descomposiciones de explicaciones aditivas de Shapley (SHAP) se usan en su análisis (Gebreyesus et al., 2023). Se desarrollaron dos modelos más, uno que incluye la variable ingresos y estrés financiero con fines comparativos y un modelo de vulnerabilidad latente. Ante la no observabilidad de los factores laborales (L_i) en la población desocupada, el algoritmo fue reentrenado restringiendo el espacio al resto de características socioeconómicas, para proyectar el riesgo de inserción informal basándose exclusivamente en condiciones pre-mercado.

3.5. Evaluación de modelos

Para garantizar la robustez y generalización, el protocolo de evaluación integró la validación cruzada con el conjunto de prueba independiente, mitigando el riesgo de sobreajuste y asegurando que las inferencias capturen dinámicas estructurales y no ruido estocástico. El diagnóstico del desempeño se fundamentó en un análisis multidimensional derivado de la matriz de confusión, contrastando sistemáticamente categorías observadas y predichas.

Respecto a los indicadores, el Accuracy se reportó como medida de exactitud global. El Área Bajo la Curva (AUC-ROC) evalúa la capacidad discriminatoria y la jerarquización del riesgo de informalidad independientemente de umbrales fijos. Para optimizar la precisión, se analizaron la sensibilidad y la especificidad; la primera maximiza la detección de la precariedad laboral, mientras la segunda garantiza la correcta identificación de trabajadores protegidos. Complementariamente, la precisión aseguró la fiabilidad de las estimaciones del modelo, mientras que el F1-score permitió ponderar el equilibrio armónico entre ambas dimensiones. Finalmente, se emplea el Coeficiente de Correlación de Matthews (MCC) como la medida definitiva de robustez, al sintetizar la consistencia diagnóstica (Chicco y Jurman, 2023).

3.6. Métricas de inferencia prospectiva: IVL y Score de Riesgo

Para cuantificar la vulnerabilidad estructural en la población desocupada, se definieron dos indicadores agregados basados en las probabilidades estimadas ($\hat{p}_i$) por el modelo de vulnerabilidad latente, ajustados por los factores de expansión poblacional (w_i).

El Score de Riesgo Promedio ($\bar{S}$): Representa la propensión media sistémica hacia la informalidad. Se calcula como el promedio ponderado de las probabilidades individuales:

$$\bar{S} = \frac{\sum \hat{p}_i \cdot w_i}{\sum w_i} \quad (6)$$

Tasa de Informalidad Latente (IVL): Cuantifica la proporción de individuos cuya configuración de activos los sitúa bajo un perfil estrictamente informal. Se define como:

$$IVL = \frac{\sum \mathbb{I}(\hat{p}_i > 0.5) \cdot w_i}{\sum w_i} \times 100, \quad (7)$$

Donde $\mathbb{I}$ es la función indicatriz de clase. El indicador calcula la media ponderada de las clasificaciones binarias, aplicando un umbral de corte estándar ($\tau = 0,50$).

4. Resultados y limitaciones

4.1. Factores socioeconómicos asociados a la informalidad

La Tabla 2 sintetiza el desempeño de los algoritmos mediante un enfoque de validación cruzada.

Tabla 2. Desempeño comparativo de modelos de clasificación

Modelo	Grp	Auc Roc	Accuracy	Sens	Espe	Precisión	F1-Scr	MCC
Regresión	Train	0,8770	0,7980	0,8470	0,7340	0,8080	0,8270	0,5860
Logística	Test	0,8730	0,7940	0,8400	0,7320	0,8050	0,8220	0,5770
Random Forest	Train	0,9090	0,8270	0,8690	0,7700	0,8330	0,8510	0,6450
	Test	0,8930	0,8100	0,8500	0,7570	0,8220	0,8360	0,6110
XGBoost (Central)	Train	0,9270	0,8460	0,8820	0,8000	0,8530	0,8670	0,6860
	Test	0,9000	0,8180	0,8560	0,7690	0,8300	0,8430	0,6280
XGBoost (Ingresos)	Train	0,9520	0,8740	0,8910	0,8510	0,8880	0,8900	0,7430
	Test	0,9280	0,8480	0,8700	0,8190	0,8640	0,8670	0,6900

Nota: Grp representa los conjuntos de entrenamiento y prueba; Sens la sensibilidad; Esp la especificad. **Elaboración propia**

En base los resultados de la Tabla 2, la regresión logística establece una línea base estable (AUC-ROC 0,87; Accuracy 0,79), sugiriendo que las relaciones lineales capturan una fracción significativa de la dinámica laboral. Su sensibilidad (0,84) permite identificar correctamente a la población vulnerable; no obstante, su limitada especificidad (0,73), precisión (0,80) e índice MCC (0,57) en el conjunto de prueba revelan una tendencia a generar errores de comisión, clasificando erróneamente a trabajadores formales como vulnerables.

El tránsito hacia arquitecturas no lineales mejora la consistencia diagnóstica. Si bien Random Forest incrementa la capacidad discriminatoria (AUC-ROC 0,89), manifiesta sensibilidad a la varianza muestral, con descensos en el MCC (0,61) y la precisión (0,82) frente al entrenamiento. En contraste, XGBoost se consolida como el modelo central de la investigación por su estabilidad y potencia discriminatoria (AUC-ROC 0,90; Accuracy 0,82). Estos resultados convergen con la evidencia de Castillo et al. (2023), quienes reportan precisiones del 84,1% mediante este algoritmo, y con los análisis de Del Pozo y Moreno (2024).

Con una sensibilidad de 0,8560 y especificidad de 0,7690, el algoritmo XGBoost reduce la clasificación errónea respecto a modelos previos. Su F1-score (0,84) y MCC (0,63) garantizan un equilibrio óptimo entre precisión (0,83) y robustez, dimensiones cruciales para analizar determinantes estructurales sin los sesgos de causalidad bidireccional descritos por Canelas (2019). Este desempeño supera niveles reportados en estudios análogos; por ejemplo, Maia de Souza et al. (2025) obtienen precisiones del 78% en encuestas regionales, mientras que Narváez y Herrera (2025) alcanzan un 75% mediante redes neuronales.

Finalmente, la configuración XGBoost (Ingresos) alcanza los niveles más altos de precisión (0,86), F1-score (0,87) y MCC (0,69), AUC-ROC de 0,93 y sensibilidad de 0,87. No obstante, este rendimiento debe interpretarse con cautela por la endogeneidad intrínseca entre ingresos y empleo. Por ello, aunque esta variante es predictivamente óptima, su utilidad para la inferencia permanece supeditada al modelo central, que ofrece un diagnóstico más puro de las carencias laborales. La Tabla 3 revela la jerarquía de predictores del modelo logístico y random forest.

Tabla 3. Coeficientes e importancia de variables de la regresión logística y random forest

Regresión Logística	Coef.	Imp Rel	Random Forest	Gain (%)
hrs_trab	-0,6629	13,5929	hrs_trab	31,3185
ramal_Servicios_Sociales_Pub	-0,5770	11,8313	ramal_Primario_Extractivo	16,0872
esc	-0,4623	9,4802	Esc	12,8927
ramal_Primario_Extractivo	0,4144	8,4985	ramal_Construccion	6,3073
ramal_Construccion	0,3306	6,7790	ramal_Servicios_Sociales_Pub	4,2453
deseo_trab_mas_Subempleo	0,2928	6,0037	exp_lab	4,1281
etnia_Indigena	0,1993	4,0868	deseo_trab_mas_Satisfecho	3,1759
ramal_Servicios_Profesionales	-0,1938	3,9737	Edad	2,4759
mat_piso_Basico_Cemento	0,1916	3,9289	mat_piso_Basico_Cemento	2,0677
num_cuartos	-0,1434	2,9412	ramal_Servicios_Consumo	1,6535
ramal_Industria_Suministros	-0,1415	2,9022	Área_urbana	1,4227
basura_disp_Eliminacion_Inad	0,1394	2,8596	Área_rural	1,3147
mat_techo_Hormigon_Losa	-0,1389	2,8483	serv_sanit_Red_Publica	1,0080
exp_lab	0,1357	2,7824	género_mujer	0,9365
mat_piso_Precario_Inadecuado	0,1323	2,7126	género_hombre	0,9131
edad	0,1272	2,6094	mat_techo_Zinc_Aluminio	0,9013
ramal_Servicios_Consumo	0,1142	2,3420	mat_piso_Estandar	0,8645
mat_piso_Alta_Calidad	-0,0887	1,8191	deseo_trab_mas_Subempleo	0,8021
estado_civil_Union_Disuelta	0,0716	1,4682	ramal_Industria_Suministros	0,7437
género_mujer	0,0628	1,2871	ramal_Servicios_Profesionales	0,7081
serv_ducha_Deficiente_NoExcl	0,0548	1,1241	num_cuartos	0,6341
estado_civil_Soltero	0,0477	0,9792	ramal_Comercio	0,6197
mat_techo_Fibrocemento_Teja	-0,0458	0,9394	mat_pared_Tradicional_Mad	0,5123
Área_rural	0,0339	0,6961	etnia_Indigena	0,4800
tenencia_viv_Cedida.Otra	-0,0228	0,4669	mat_piso_Alta_Calidad	0,3806
mat_pared_Tradicional_Madera	0,0207	0,4244	mat_techo_Hormigon_Losa	0,3645
serv_sanit_Pozo_Septico	0,0113	0,2313	mat_piso_Precario_Inadecuado	0,2661

tipo_viv_Precaria_Vulnerable	0,0100	0,2058	tenencia_viv_Arrendada	0,2438
agua_fuente_Fuente_Alterna	0,0090	0,1856	basura_disp_Eliminacion_Inad	0,2395
via_acceso_NoPavimentada	0,0000	0,0000	basura_disp_Recoleccion_Frm	0,2158
tenencia_viv_Propia	0,0000	0,0000	Resto de variables	<0,213

Nota: Coef. corresponde al coeficiente (*log-odds*); Imp. rel. indica la importancia relativa. Gain indica la ganancia como contribución porcentual

Elaboración propia

Respecto a los coeficientes e importancia relativa del modelo logístico (Tabla 3). La dimensión de capital humano y laboral, hrs_trab (-0,66), esc (-0,46) e inserción en servicios sociales públicos (-0,58) reducen significativamente el riesgo de informalidad, validando la teoría del capital humano (Becker, 1992). Bajo el enfoque estructuralista (Tokman, 1979), la participación en los sectores primario extractivo (0,41) y construcción (0,33) eleva la probabilidad de inserción precaria, mientras que servicios profesionales (-0,19) e industria de suministros (-0,14) la mitigan. El deseo de trabajar más (0,29) refleja presiones por subempleo, mientras el efecto positivo de la experiencia laboral (0,14) sugiere heterogeneidad no observada.

En lo sociodemográfico, la autoidentificación indígena (0,19) es dominante, superando a la edad (0,12), estado civil (0,07), género (0,06) y área (0,03). Estos hallazgos coinciden con Castillo et al. (2022), aunque estos últimos enfatizan más el peso del género, cuya relevancia fluctúa según entre modelos (Jara y Rattenhuber, 2022). Los resultados sobre la edad difieren parcialmente de la literatura que asocia una mayor vulnerabilidad a la población joven (Da Silva Bichara et al., 2022; Armijos Orellana et al., 2023). Finalmente, en la precariedad habitacional, los pisos de cemento (0,19), tierra (0,13) y paredes de madera (0,02) incrementa el riesgo, mientras que materiales de alta calidad en techos (-0,13), fibrocemento (-0,04) y pisos (-0,08) lo reducen. El número de cuartos (-0,14) destaca como el predictor patrimonial clave. En servicios, la eliminación inadecuada de basura (0,14) tiene un impacto superior a los aportes marginales del servicio de ducha (0,05), suministro de agua (0,01) y régimen de tenencia.

El modelo Random Forest confirma la jerarquía predictiva, donde la intensidad horaria (31,3%), el sector primario (16,1%) y la escolaridad (12,9%) dominan la clasificación. A diferencia del enfoque paramétrico, este algoritmo captura efectos no lineales en variables como la experiencia y la edad, cuya relevancia se incrementa al considerar interacciones complejas. La marcada heterogeneidad sectorial refuerza la naturaleza fragmentada del fenómeno, mientras que hay peso marginal de factores habitacionales y servicios (< 2%) a excepción del suelo de cemento. La Tabla 4 revela la importancia relativa de variables para dos modelos comparativos.

Tabla 4. Comparativa de importancia de variables de Random Forest y XGBoost.

Variables XGBoost Central	Gain	Variables XGBoost Ingresos	Gain
		ingrl_log	46,9337
hrs_trab	29,2258	hrs_trab	13,0275
esc	14,7086	ramal_Primario_Extractivo	8,3762
ramal_Primario_Extractivo	13,7918	esc	6,3833
ramal_Servicios_Sociales_Pub	5,5963	ramal_Construccion	4,3369
exp_lab	4,9321	exp_lab	3,3486
ramal_Construccion	4,6272	edad	2,7336
edad	3,5173	ramal_Servicios_Sociales_Pub	1,9424


deseo_trab_mas_Satisfecho	2,9996	rama1_Servicios_Consumo	1,0013
mat_piso_Basico_Cemento	1,7990	deseo_trab_mas_Satisfecho	0,8289
serv_sanit_Red_Publica	1,7486	género_X1	0,7885
num_cuartos	1,3329	mat_piso_Basico_Cemento	0,7299
rama1_Servicios_Profesionales	1,3029	num_cuartos	0,7204
rama1_Servicios_Consumo	1,0599	Área_urbana	0,6106
mat_techo_Zinc_Aluminio	0,9374	serv_sanit_Red_Publica	0,5235
rama1_Industria_Suministros	0,9146	mat_techo_Zinc_Aluminio	0,5227
Área_urbana	0,9056	rama1_Servicios_Profesionales	0,5081
etnia_Indigena	0,8851	etnia_Indigena	0,5046
deseo_trab_mas_Subempleo	0,6827	rama1_Industria_Suministros	0,4719
género_hombre	0,6590	mat_techo_Hormigon_Losa	0,4290
mat_piso_Precario_Inadecuado	0,4912	género_mujer	0,4149
mat_piso_Estandar	0,4891	mat_piso_Alta_Calidad	0,3718
mat_techo_Hormigon_Losa	0,4856	Área_rural	0,3365
mat_piso_Alta_Calidad	0,4751	rama1_Comercio	0,3326
rama1_Comercio	0,4687	estado_civil_Soltero	0,2536
mat_pared_Tradicional_Mad	0,4546	estado_civil_Union_Disuelta	0,2416
Área_rural	0,4509	mat_piso_Estandar	0,2391
basura_disp_Recoleccion_Form	0,4195	basura_disp_Recoleccion_Frm	0,2242
etnia_Mestizo	0,3458	mat_pared_Tradicional_Mad	0,2105
género_mujer	0,3102	tenencia_viv_Arrendada	0,2015
estado_civil_Union_Disuelta	0,3091	deseo_trab_mas_Subempleo	0,1939
estado_civil_Pareja_Estable	0,3030	tenencia_viv_Propia	0,1850
tenencia_viv_Propia	0,3026	via_acceso_Moderna_Pavimentada	0,1751
estado_civil_Soltero	0,2845	etnia_Mestizo	0,1687
tenencia_viv_Arrendada	0,2574	mat_techo_Fibro cemento_Teja	0,1679
via_acceso_Moderna_Pavimentada	0,2526	estado_civil_Pareja_Estable	0,1565
mat_techo_Fibro cemento_Teja	0,2363	tenencia_viv_Cedida_Otra	0,1514
tenencia_viv_Cedida_Otra	0,2203	mat_piso_Precario_Inadecuado	0,1488
agua_fuente_Red_Publica	0,2161	etnia_other	0,1240
serv_ducha_Privado_Exclusivo	0,1879	serv_sanit_Pozo_Septico	0,1189
tipo_viv_Consolidada_Indep	0,1864	agua_fuente_Red_Publica	0,1174
via_acceso_NoPavimentada	0,1858	via_acceso_NoPavimentada	0,1155
serv_sanit_Pozo_Septico	0,1747	tipo_viv_Consolidada_Indep	0,1146
etnia_other	0,1744	serv_ducha_Privado_Exclusivo	0,1066
mat_pared_Hormigon_Ladrillo	0,1720	basura_disp_Eliminacion_Inad	0,0990
agua_fuente_Fuente_Alterna	0,1669	mat_pared_Hormigon_Ladrillo	0,0984
basura_disp_Eliminacion_Inad	0,1534	agua_fuente_Fuente_Alterna	0,0894
tipo_viv_Precaria_Vulnerable	0,1007	tipo_viv_Precaria_Vulnerable	0,0698
serv_ducha_Deficiente_NoExcl	0,0987	serv_ducha_Deficiente_NoExcl	0,0513

Elaboración propia

El modelo XGBoost ratifica la estructura jerárquica donde pocas variables tienen mayor capacidad predictiva con una rápida caída en la contribución marginal del resto. Al agrupar por

dimensiones, la estructura y dinámica laboral (60,66%) domina el modelo, seguida por el capital humano (23,15%), mientras que las dimensiones habitacionales (5,58%), sociodemográfica (4,62%), infraestructura (3,60%) y patrimonio (2,40%) tienen menor aporte. Esta jerarquía converge con evidencia previa que vincula la informalidad con brechas de acceso a servicios básicos (Goetz, 2022; Espinosa et al., 2025; Llerena et al., 2025). La relevancia de la experiencia laboral (4,93%), edad (3,52%) y el deseo de trabajar más (3%) concuerda con Martínez Valarezo et al. (2022), al identificar la presión del desempleo como catalizador. Finalmente, el modelo con ingresos muestra una dominancia predictiva del `ingrl_log` (46,9%), sugiriendo que la capacidad explicativa de los factores habitacionales es absorbida por esta variable. El predictor 'déficit financiero' resultó irrelevante para el modelo. Pese a la posible endogeneidad, los pilares estructurales como `hrs_trab` (13%), `rama1_Primary_Extractivo` (8,40%) y `esc` (6,4%) mantienen su relevancia, evidenciando estabilidad en la estructura predictiva. La Figura 1 muestra los valores SHAP del modelo central sin ingresos.

Figura 1. Distribución del impacto de las variables en XGBoost (Valores SHAP)



Elaboración propia

La descomposición SHAP (Figura 1) revela que la intensidad horaria (`hrs_trab`) y la exclusión de servicios públicos son los principales motores del riesgo de informalidad, vinculando jornadas extensas con precariedad de subsistencia. Mientras la escolaridad actúa como el principal mitigador, la trayectoria laboral y la edad muestran una tendencia inversa que sugiere un efecto de histéresis: la acumulación de capital específico en el sector informal limita la movilidad ascendente (Bobba et al., 2021). Asimismo, el modelo identifica barreras sistémicas en la autoidentificación indígena y la precariedad habitacional, cuyos impactos positivos son consistentes y compactos. La dispersión de los valores SHAP confirma que la exclusión sectorial y la carga horaria constituyen los pivotes diagnósticos del fenómeno, consolidando la utilidad de este enfoque para la focalización estratégica de políticas públicas.

4.2. Análisis de Vulnerabilidad Latente: Predicción para la población desocupada.

El modelo XGBoost de vulnerabilidad latente para la población desocupada, omite variables laborales para centrarse en atributos pre-mercado. La integración de pesos muestrales asegura representatividad poblacional. Las métricas de desempeño se presentan en la Tabla 5.

Tabla 5. Evaluación del desempeño predictivo del modelo XGBoost de vulnerabilidad latente


Modelo	Grp	Auc R	Accuracy	Sensibilidad	Especificidad	Precisión	F1-scr	Mcc
XGBoost	Train	0,832	0,753	0,825	0,659	0,761	0,792	0,492
latente	Test	0,824	0,749	0,822	0,652	0,757	0,788	0,483

Nota: Coef. corresponde al coeficiente (*log-odds*); Imp. rel. indica la importancia relativa. Gain indica la ganancia como contribución porcentual

Elaboración propia

Los resultados en Tabla 5 exhiben una alta robustez con un AUC-ROC de 0,824 y un Accuracy de 0,749 en el conjunto de prueba. Pese a la restricción de variables laborales, la reducida brecha de generalización (0,4%) confirma la estabilidad de los estimadores y la ausencia de sobreajuste. La sensibilidad (0,822) se consolida como el principal atributo de diagnóstico, permitiendo detectar correctamente al 82% de los individuos con riesgo estructural, mientras que la especificidad (0,652) refleja una sobre identificación cautelosa propia de modelos preventivos. Este equilibrio se traduce en una precisión de 0,757 y un F1-score de 0,788, garantizando fiabilidad en las detecciones positivas. Finalmente, el MCC de 0,483 ratifica la consistencia, posicionando al modelo como una herramienta eficaz para la identificación ex-ante de la vulnerabilidad laboral. Las importancias relativas se observan en la Figura 2.

Figura 2. Principales importancias relativas del modelo de vulnerabilidad latente



Elaboración propia

La figura 2 refleja las ganancias y confirmando la hegemonía del capital humano (67,50%), donde la escolaridad se erige como el determinante crítico ante la ausencia de factores laborales, secundada por la experiencia (9,7%) y la edad (9,6%), mientras la localización urbana (5,9%)

aporta la dimensión territorial. El resto del peso predictivo se distribuye entre dimensiones sociodemográficas (9,97%), habitacionales (10,77%), infraestructura (9,45%) y estabilidad patrimonial (2,31%). En las condiciones de habitabilidad y servicios, destaca el saneamiento (5,5%), calidad del piso (4,7%) y gestión de residuos (2%); este último es consistente con la limitada provisión de bienes públicos en entornos precarios (Taweesan et al., 2025). Factores como el material de techo, número de cuartos, etnia indígena y materiales precarios muestran contribuciones medias (1,7%–2,0%), mientras que el acceso vial, servicios básicos y tenencia presentan impactos marginales. La acumulación de privaciones se sintetiza en la Tabla 6.

Tabla 6. Magnitud nacional y fiabilidad diagnóstica de la vulnerabilidad laboral latente.

Indicador	Valor	Descripción e implicación económica
Tasa de Informalidad Latente (IVL)	33,30%	Proporción de desocupados con perfil estructural de informalidad, clasificación binaria $\hat{y} > 0,50$.
Score de Riesgo Promedio	38,70%	Probabilidad intrínseca media de inserción precaria en toda la población desocupada.
Sensibilidad del Diagnóstico	82,20%	Capacidad del modelo para identificar correctamente los perfiles de vulnerabilidad crítica.

Elaboración propia

Los resultados de la inferencia prospectiva (Tabla 6) revelan un Índice de Vulnerabilidad Latente (IVL) del 33,30%, indicando que un tercio de los desocupados posee una configuración de activos que preconfigura su inserción informal. El Score de Riesgo Promedio (38,70%) evidencia una fragilidad sistémica mayor, sugiriendo que la búsqueda de empleo inicia bajo una elevada probabilidad de precariedad intrínseca. Esta magnitud es consistente con el peso de la informalidad en la estructura productiva nacional, estimado en el 32% del PIB (Mejía Chávez et al., 2023), y se alinea con el promedio del 33,5% en economías emergentes (Asllani et al., 2025). Estos hallazgos ratifican la validez del modelo.

La fiabilidad de estas estimaciones se sustenta en la elevada sensibilidad (82,20%), que garantiza una identificación alta de los perfiles de riesgo crítico. Si bien la especificidad (0,652) implica una sobre identificación moderada, este margen resulta preferible desde una perspectiva de política pública, pues favorece la intervención temprana y preventiva frente al riesgo de exclusión. Los hallazgos permiten inferir que, en Ecuador las deficiencias acumuladas en educación e infraestructura generan una fuerza laboral estructuralmente frágil, que perpetúa la persistencia de la informalidad como un destino determinado por las carencias previas.

Tabla 7. Taxonomía de la Vulnerabilidad Laboral Latente en Ecuador

Segmento	Población	Riesgo	Esc	Exp	Edad	Saneamiento	Piso prec
Bajo (0-30%)	43,48%	15%	16,42	9,93	32,25	95,73%	1,78%
Moderado (30-70%)	41,94%	48%	11,41	11,64	28,95	85,01%	5,38%
Crítico (IVL) (>70%)	14,58%	82%	7,73	24,14	37,81	56,36%	20,47%

Nota: Esc es escolaridad media; Exp es experiencia laboral media; Piso Prec cuantifica piso precario

Elaboración propia

La taxonomía de la vulnerabilidad (Tabla 7) revela una polarización estructural donde la informalidad opera como una trampa de activos multidimensional. El segmento crítico

(14,58%) presenta un riesgo de informalidad del 82%, revelando un fenómeno de histéresis: pese a ostentar la mayor trayectoria laboral (24,1 años), la escasa escolaridad (7,7 años) y el colapso de activos habitacionales de saneamiento (56,36%) y piso precario (20,47%) favorecen una inserción precaria irreversible. Por el contrario, el segmento de bajo riesgo (43,48%) exhibe una probabilidad de informalidad de apenas el 15%, protegido por una alta escolaridad (16,4 años) y estabilidad habitacional. Consistente con el 51% de la OIT (2025), el estudio ratifica la informalidad como una trayectoria preconfigurada por privaciones estructurales ex-ante.

4.3.Limitaciones

Se reconoce limitaciones en términos de identificación causal y dinámica temporal. Aunque el uso de XGBoost optimiza el rendimiento predictivo, reduce la transparencia estructural inherente a la econometría tradicional, restringiendo el alcance de los hallazgos a un marco estrictamente predictivo. Por otro lado, el modelo de vulnerabilidad latente, al omitir variables laborales, podría sobreestimar el peso del capital humano, específicamente la escolaridad, como proxy de condiciones estructurales, sugiriendo que futuras especificaciones se beneficiarían de la inclusión de métricas de comportamiento. Finalmente, la naturaleza transversal de los datos impide el análisis de transiciones longitudinales; en consecuencia, variables como la edad y la experiencia deben interpretarse como indicadores de trayectorias acumuladas y no como motores de evolución causal hacia la informalidad.

5. Conclusión y discusión

Esta investigación implementa un enfoque de aprendizaje automático para predecir la informalidad en Ecuador mediante factores socioeconómicos. Se empleó una partición estratificada (80/20) con ponderaciones muestrales y validación cruzada. El modelo central XGBoost alcanzó una exactitud del 90%, superando al modelo logístico y random forest. Complementariamente, el modelo de vulnerabilidad latente, que excluye variables del flujo laboral para centrarse en factores pre-mercado de los desocupados alcanzó una exactitud del 82%. El modelo logístico evidenció una marcada heterogeneidad sectorial, donde actividades como el sector primario, la construcción y los servicios de consumo incrementan la probabilidad de inserción informal. Aunque los hallazgos ratifican el rol protector de la escolaridad, su eficacia está supeditada a una demanda laboral de mayor complejidad tecnológica (Kaplinsky y Kraemer-Mbula, 2022; Mejía Chávez et al., 2023).

La arquitectura jerárquica de XGBoost asigna un peso predominante a la dinámica laboral y al capital humano con 83,83%, frente al 16,17% de los factores sociodemográficos y habitacionales. En la especificación de vulnerabilidad latente, el capital humano concentra el 67,50% de la importancia predictiva, delegando el 32,50% a las dimensiones sociodemográficas, habitacionales, servicios y patrimoniales. Particularmente, la precariedad del suelo, el déficit de saneamiento y número de cuartos operan como preconfiguraciones estructurales que proyectan trayectorias informales ex ante. Finalmente, la inferencia prospectiva revela una vulnerabilidad crítica: un tercio de la población desocupada enfrenta un alto riesgo de informalidad, con un score de riesgo promedio individual cercano al 40%.

Los hallazgos demuestran que la informalidad en Ecuador emerge del nexo entre dinámicas laborales y carencias estructurales. En consecuencia, las estrategias de formalización deben

trascender la acumulación de capital humano, integrando la reducción de brechas en infraestructura y servicios básicos debido a sus externalidades positivas sobre la calidad del empleo. Futuras investigaciones deberían emplear aprendizaje no supervisado para delinear tipologías latentes de informalidad, así como arquitecturas de deep learning con datos de alta frecuencia para capturar la volatilidad del fenómeno ante choques macroeconómicos.

6. Bibliografía

- Ali, Z. A., Abduljabbar, Z. H., Taher, H. A., Sallow, A. B., & Almufti, S. M. (2023). Exploring the power of eXtreme gradient boosting algorithm in machine learning: A review. *Academic Journal of Nawroz University (AJNU)*, 12(2).
- Armijos Orellana, A.C., Maldonado-Matute, J.M., Guerrero-Maxi, P.F., & González Calle, M.J. (2023). Informalidad laboral y criminalidad juvenil en Latinoamérica y Ecuador. *Revista Ciencias Pedagógicas e Innovación*, 10(2), 144–158. <https://doi.org/10.26423/rcpi.v10i1.597>
- Asllani, A., Dell’Anno, R., & Schneider, F. (2025). Global estimates of informal economies and new insights for 152 countries (1997–2022): Using an enhanced modelling approach. *Economic Analysis and Policy*. <https://doi.org/10.1016/j.eap.2025.11.027>
- Aurazo, J., & Gasmi, A. (2025). Informality and financial inclusion in Peru: Evidence from panel data. *Finance Research Letters*, 60, 100200. <https://doi.org/10.1016/j.rspp.2025.100200>
- Bargain, O., Etienne, A., & Melly, B. (2021). Informal pay gaps in good and bad times: Evidence from Russia. *Journal of Comparative Economics*, 49(3), 693–714. <https://doi.org/10.1016/j.jce.2021.02.002>
- Becker, G. S. (1992). Human capital and the economy. *Proceedings of the American philosophical society*, 136(1), 85-92.
- Berniell, I., Berniell, L., de la Mata, D., Edo, M., & Marchionni, M. (2021). Gender gaps in labor informality: The motherhood effect. *Journal of Development Economics*, 150, 102599. <https://doi.org/10.1016/j.jdeveco.2020.102599>
- Bobba, M., Flabbi, L., Levy, S., & Tejada, M. (2021). Labor market search, informality, and on-the-job human capital accumulation. *Journal of Econometrics*, 223(2), 433–453. <https://doi.org/10.1016/j.jeconom.2019.05.026>
- Bulale, A. A., & Ibrahim, M. I. (2026). Informality in business, survival modes, and state absence in Somalia. *Cities*, 170, 106591. <https://doi.org/10.1016/j.cities.2025.106591>
- Canelas, C. (2019). Informality and poverty in Ecuador. *Small Business Economics*, 53(4), 1097–1115. <https://doi.org/10.1007/s11187-018-0102-9>
- Castillo, R. A., Garcia-Guerrero, J., Moreno, L. E., Rosales, C. R., Del Pozo, D., Villacís, A., & Feijoó, E. (2023). Imputación de información en encuestas de hogares a través de técnicas de machine learning: Análisis del caso ecuatoriano. *Cuaderno de Trabajo No. 15*. INEC.

- Castillo, R. A., Ortiz, J. C., & Encalada, J. (2022). Determinantes de la informalidad laboral en Ecuador: Un análisis con modelos probit y descomposición Oaxaca-Blinder. *The International Journal of Business Management and Technology*, 6(2), 308–320.
- Chicco, D., & Jurman, G. (2023). The Matthews correlation coefficient (MCC) should replace the ROC AUC as the standard metric for assessing binary classification. *BioData mining*, 16(1), 4.
- Da Silva Bichara, J., Castillo Robayo, C., & Delgado, J. L. (2022). La informalidad y la duración del desempleo de los jóvenes en Latinoamérica. Especial referencia a Ecuador. *Revista de Economía Mundial*, 60, 125–149. <https://doi.org/10.33776/rem.v0i60.5470>
- Del Pozo, D., & Moreno, L. (2024). Movilidad intergeneracional en Ecuador: Una primera aproximación. *Cuadernos de Trabajo No. 19*. Instituto Nacional de Estadística y Censos (INEC).
- Díaz-Sánchez, J. P., & Correa, J. (2024). Migración y empleo formal en Ecuador: Evidencia de los censos de población. *Research in Globalization*, 6, 100198. <https://doi.org/10.1016/j.resglo.2024.100198>
- Espinosa, O., Bejarano, V., Arias, M.-L., & Gonsales, J. I. (2025). Informal workers in the rural sector in Colombia: Living conditions and social security. *Regional Science Policy & Practice*, 17, 100200. <https://doi.org/10.1016/j.rspp.2025.100200>
- Felix, J., Alexandre, M., & Lima, G. T. (2024). Applying Machine Learning Algorithms to Predict the Size of the Informal Economy. *Computational Economics*, 65, 1169–1189. <https://doi.org/10.1007/s10614-024-10593-6>
- Franco Coello, M. R., Sandoval Cuji, M. M., Castillo Plaza, I. A., & Álava Murillo, A. G. (2025). Modelo híbrido predictivo de quiebra empresarial basado en machine learning. *Horizon International Journal*, 3(2), 154–176.
- Gebreyesus, Y., Dalton, D., Nixon, S., De Chiara, D., & Chinnici, M. (2023). Machine learning for data center optimizations: feature selection using Shapley additive exPlanation (SHAP). *Future Internet*, 15(3), 88.
- Goetz, J. M. (2022). The impact of informal and rural labour markets on poverty reduction: A mixed methods study of artisanal and small-scale gold mining (ASGM) in Northwest Tanzania. *World Development*, 158, 106012. <https://doi.org/10.1016/j.worlddev.2022.106012>
- Hilbe, J. M. (2025). Logistic regression. In *International encyclopedia of statistical science* (pp. 1386-1390). Berlin, Heidelberg: Springer Berlin Heidelberg.
- Instituto Nacional de Estadística y Censos. (2025). *Registro Estadístico de Empresas 2024*. Recuperado el 10 de diciembre de 2025, de [Registro Estadístico de Empresas \(REEM\) – 2024 \(semi – definitivo\)](#)

- Instituto Nacional de Estadística y Censos. (2025). *V Principales resultados de la Encuesta Nacional de Empleo, Desempleo y Subempleo – Anual*. Recuperado el 10 de diciembre de 2025, de [Presentación de PowerPoint](#)
- Iranzad, R., & Liu, X. (2025). A review of random forest-based feature selection methods for data science education and applications. *International Journal of Data Science and Analytics*, 20(2), 197-211.
- Iranzad, R., & Liu, X. (2025). A review of random forest-based feature selection methods for data science education and applications. *International Journal of Data Science and Analytics*, 20(2), 197-211.
- Jara, H., & Rattenhuber, P. (2022). Tax-benefit reforms and female labor supply in Ecuador: Evidence from microsimulation. *UNU-WIDER Working Paper* 2022/178. <https://doi.org/10.35188/UNU-WIDER/2022/178-5>
- Kaplinsky, R., & Kraemer-Mbula, E. (2022). Innovation and uneven development: The challenge for low-and middle-income economies. *Research Policy*, 51(2), 104394.
- Lewis, W. A. (1954). *Economic Development with Unlimited Supplies of Labour*. The Manchester School. Manchester: The Manchester School.
- Llerena Pinto, M. C., Mirzabaev, A., & Qaim, M. (2025). Effects of recurrent rainfall shocks on poverty and income distribution in rural Ecuador. *World Development*, 185, 107107. <https://doi.org/10.1016/j.worlddev.2025.107107>
- Maia de Souza, C., Ponce-López, R., Peraza-Mues, G. G., Domínguez-Cristerna, A. A., & Miller, E. J. (2025). Imputing informal workers for transportation modeling in Latin America by the use of machine learning techniques. *Latin American Transport Studies*, 3, 100032. <https://doi.org/10.1016/j.latran.2025.100032>
- Martínez Valarezo, J. D., Uriguen Aguirre, P. A., & Campuzano Vásquez, J. A. (2022). Empleo informal y motivaciones intrínsecas para participar en la venta ambulante en la ciudad de Machala, Ecuador. *Revista de Ciencias Sociales y Humanidades*, 7(31). <https://doi.org/10.46652/rgn.v7i31.886>
- Mejía Chávez, M., Mejía Chávez, L., Mejía Morales, M., & Lara Haro, D. (2023). Is Ecuador an informal economy? An approach to the size of the Ecuadorian informal sector from the perspective of multivariate analysis. *Cuestiones Económicas*, 33(2). <https://doi.org/10.47550/RCE/33.2.6>
- Mincer, J. A. (1974). The human capital earnings function. In *Schooling, experience, and earnings* (pp. 83-96). NBER.
- Molina Vera, A., Rivadeneira Alava, A., & Rosero Moncayo, J. (2015). Actualización metodológica: el empleo en el sector informal. *Revista de Estadística y Metodologías*, 1, 55–62.
- Narváez, I. A., & Herrera, E. P. (2025). Análisis del desempleo en Ecuador con modelos econométricos clásicos y propuesta usando machine learning. *IDEAS*, 7(2).

- Nguyen, T. T., & Ho, T. H. (2025). Financial crises and informal employment: Evidence from panel data. *Economic Modelling*, 126, 106934. <https://doi.org/10.1016/j.econmod.2024.106934>
- Organización Internacional del Trabajo. (2025). *Base de datos de estadísticas del trabajo (ILOSTAT)*. Recuperado el [10] de [diciembre] de 2025, de [Estadísticas en economía informal - ILOSTAT](#)
- Taweesan, A., Koottatep, T., Kanabkaew, T., Eamrat, R., Pussayanavin, T., & Polprasert, C. (2025). Unveiling sustainable solutions for municipal waste management through machine learning. *Environmental Challenges*, 101333.
- Tokman, V. E. (1979). An Exploration into the Nature of Informal—Formal Sector Relationships. In *The Urban Informal Sector* (pp. 1065–1075). Elsevier. <https://doi.org/10.1016/b978-0-08-024270-5.50007-7>
- Torres-Favela, J., & Luna, J. (2025). The role of informality in macroeconomic stability during pandemics. *Latin American Trade and Business*, 4(1), 100150. <https://doi.org/10.1016/j.latchb.2024.100150>

7. Anexos

Anexo A. Descripción de categorías de variables por dimensión socioeconómica

Variable	Símbolo	Categoría
Empleo sector informal	informal	1: Informal 0: formal
Escolaridad	esc	Continua
Experiencia laboral	exp_lab	Continua
Edad	edad	Continua
Etnia	etnia	1: Mestizo 2: Indígena 3: Afroecuatoriano 4: Otros_Minoristas
Estado civil	estado_civil	1: Pareja_Estable 2: Soltero 3: Unión_Disuelta
Área	area	1: Urbana 2: Rural
Género	género	1: Hombre 2: Mujer
Rama de actividad	ramal	1: Comercio 2: Primario_Extractivo 3: Industria_Suministros 4: Construcción 5: Servicios_Consumo 6: Servicios_Profesionales 7: Servicios_Sociales_Públicos 8: Otros_Marginales

Ingresos laborales	ingrl_log	Continua
Horas de trabajo	hrs_trab	Continua
Deseo de trabajar	deseo_trab_mas	1: Satisfecho 2: Presion_Subempleo 3: No_Disponible
Material del piso	mat_piso	1: Estandar 2: Alta_Calidad 3: Básico_Cemento 4: Precario_Inadecuado
Material del techo	mat_techo	1: Zinc_Aluminio 2: Hormigon_Losa 3: Fibrocemento_Teja 4: Precario_Inadecuado
Material de paredes	mat_pared	1: Hormigon_Ladrillo 2: Tradicional_Madera 3: Precario_Ligero
Saneamiento	serv_sanit	1: Red_Publica 2: Pozo_Septico 3: Deficiente_Precario
Servicio de higiene	serv_ducha	1: Privado_Exclusivo 2: Deficiente_NoExclusivo
Suministro de agua	agua_fuente	1: Red_Publica 2: Precario_Excluido 3: Fuente_Alterna
Acceso a la vivienda	via_acceso	1: Moderna_Pavimentada 2: Permanente_NoPavimentada 3: Precaria_Inaccesible
Eliminación de basura	basura_disp	1: Recoleccion_Formal 2: Eliminacion_Inadecuada
Material de cocción	mat_cocina	1: Moderno_Convencional 2: Solido_Contaminante
Tipo de vivienda	tipo_viv	1: Consolidada_Independiente 2: Marginal_Subestandar 3: Precaria_Vulnerable
Tenencia de vivienda	tenencia_viv	1: Propia 2: Arrendada 3: Cedida_Prestada
Número de cuartos	num_cuartos	Continua
Gasta más	gasta_mas	1: Gasta_más 2: No_gasta_más

Elaboración propia